

XÓY DNG H THNG RAG NHN BIT CU TRỮC VỊ THI GIAN HIU LC H TR TRA CU PHÒP LUT GIAO THŨNG VIT NAM VI TRỒCH DN CÚ TH KIM CHNG

Tổn ting Anh: *A Structure-Aware and Temporal RAG System for Vietnamese Traffic Law Question Answering with Verifiable Citations*

Bi cnh vị bị toàn

Ngì đón khi tra cu phòp lut giao thũng ng b Vit Nam thng phi c nhiu vn bn dĩ, t i chiu gia Lut, Ngh nh, Thũng t vị còc vn bn sa i hoc thay th. Mt cú hi tng nh n gin, chng hn mc x pht i vị mt hnh vi, cú th cú òp òn khòc nhau tũy loi phng tin, iu kin òp dng vị thi im xy ra hnh vi. Cú tr li ỹng cho mt hnh vi nm 2023 cha chc ỹng cho hnh vi tng t nm 2026.

Còc chatbot da trỏn mũ hnh ngũn ng ln cú th tr li nhanh nhng vn tn ti nguy c to sai mc pht, gòp ni dung t nhiu phiỏn bn hoc a ra iu, Khon, im khũng tn ti. Còch tip cn RAG thũng thng theo chui PDF - chunk - vector database - LLM cng cha gii quyt y còc c im quan trng ca d liu phòp lut:

- cu trũc phón cp Chng, Mc, iu, Khon vị im vi nhón im ting Vit a) b) c) d)) e), trong ú ranh gii phòp lý phi trũng ranh gii trỏch dn;
- hiu lc theo thi gian: mt quy nh ch ỹng trong khong [effective_from, effective_to), vn bn cú th b sa i, thay th hoc bói b tng phn;
- quan h tham chiu gia còc quy nh: iu, Khon, im dn chiu ln nhau, quy nh x pht thng gn kỏm quy nh tr im gii phỏp lòi xe;
- trỏch dn o giỏc: mũ hnh cú th to citation khũng tn ti hoc gòp ni dung ỹng vi provision_id sai;
- b sút retrieval theo nh danh chỏnh xỏc: vector search thun tũy cú th b sút s hiu vn bn, s iu, s Khon hoc nhón im cú tỏnh quyt nh;
- cú hi a bng chng: mt cú hi cú th yỏu cu va mc pht va s im tr, h thng khũng c tr li mt na d ca cú hi.

tị xóy dng mt h thng RAG chuyỏn bit cho phòp lut giao thũng ng b Vit Nam. H thng khũng ch tỏm on vn cú ni dung gn vị cú hi mị cùn phi xỏc nh ỹng n v phòp lý, ỹng phiỏn bn vn bn ti thi im c hi, m rng ỹng còc quy nh liỏn quan vị kim chng tng trỏch dn trc khi tr kt qu.

Mc tiếu h thng

H thng hng n còc mc tiếu sau:

- Xóy dng Parser Router nh tuyn tị lii qua Docling hoc MinerU theo c tòngh tị lii vı quality gate, cıng Canonical Document IR parser-neutral do d òn s hu.
- Xóy dng Legal Structure Extractor nhn đın Chng, Mc, iu, Khon, im, h tr nhõn im tıng Vit (k c) vı gi li còc im ngn hp l.
- Mũ hnh húa quan h tham chiu gia còc quy nh bng ProvisionReference, DocumentRelation vı LegalEffectEvent lu trong PostgreSQL, khũng dıng Neo4j.
- Biu đın vn bn vı iu khon bng LegalDocument vı LegalProvision vı nh danh n nh, tòngh `source_text` vı `retrieval_text`, kóm khong hıu lc.
- Kt hp exact legal lookup, dense retrieval vı sparse BM25 trong Qdrant bng RRF, kóm reranking vı m rng ng cnh phòp lý theo quan h.
- Xóy dng evidence plan vı Evidence Completeness Gate khũng tr li na vı cho cóu hi a bng chng.
- H tr cóu hi v quy nh hın hınh, quy nh trong quò kh vı so sòngh hai giai on.
- Sınh cóu tr li cú cu trıcc cp claim bng Gemini 3.5 Flash, trong ú mi claim phi gı nh danh iu khon thuc context ò truy xut.
- Kim chng cóu tr li bng sòu tng verification vı bt bin Returned Invalid Citation Rate bng 0.
- T chi tr li khi corpus khũng bng chng hoc trỏch đn khũng th c xòc minh, thay vớ tòm web t do.
- Thıt lp observability bng Langfuse vı i chiu vı baseline RAGFlow bốn ngoi.
- ònh giò h thng bng gold set chun vı bn suite thờ nghim A-D.

H thng phc v tra cu vı h tr tòm cn c, khũng thay th t vn ca lut s hoc kt lun ca c quan cú thm quyn.

Phm vı

Phm vı khúa lun tp trung vıo phòp lut giao thũng ng b Vit Nam vı khong 20 n 30 vn bn chòngh thng, trong ú cú vn bn hın hınh, vn bn lch s vı òt nht 5 chui sa i, thay th hoc bõi b.

Còc chc nng bt buc gm:

- np vı x lý PDF qua Parser Router vı Docling chòngh vı MinerU ph/fallback;
- chun húa sang Canonical Document IR vı trỏch xut cu trıcc phòp lý;
- gii quy t quan h tham chiu chỏo vı quan h hıu lc;

- review d liu trc khi index;
- truy xut a tng exact lookup, dense, sparse vi RRF vi reranking;
- lc theo thi gian hieu lc;
- hi òp hin hinh, lch s vi so sòn;
- kim tra tòn y bng chng trc khi sinh cõu tr li;
- kim chng trõch dn sòu tng;
- t chi tr li khi thiu cn c;
- giao din chat, tøm kim vi xem on ngun;
- b ònh giò 200 cõu vi bõo cõo cõc suite thờ nghim A-D.

tại khũng trin khai open web search to cõu tr li, autonomous multi-agent, toin b h thng phõp lut Vit Nam, knowledge graph hoc Neo4j, fine-tuning mĩ hõnh, ng dng di ng, voice chatbot, microservices hoc RAGFlow lĩm nn tng chõnh. RAGFlow ch c dũng lĩm baseline so sòn bõn ngoi, chy trong mĩi trng benchmark riõng.

Kin trũc tng th

H thng c chia thĩnh hai pipeline c lp, c iu phi bi LangGraph nh mt controlled workflow cú cõc nhõnh xõc nh trc, khũng phi agent t tr. Mi tng quan trng phõt trace v Langfuse; observability nm ngoi ng ti hn tõnh ỹng n.

Pipeline x lý tĩ liu ngoi tuyñ

Ngun vn bn chõnh thng → Source Registry vi Corpus Manifest → Ingestion Queue (Redis + Dramatiq) → Parser Router (Docling | MinerU) → Canonical Document IR → Legal Structure Extractor → Legal Reference Resolver → Temporal and Amendment Resolver → Quality Gates → Human Review → PostgreSQL → Embedding and Sparse Indexing → Qdrant

Parser Router c trc tip tĩ liu ngun bng Docling (parser chõnh) hoc MinerU (parser ph, fallback vi challenger), quyñ nh theo c tõnh tĩ liu vi kt qu quality gate. u ra parser c chun hĩa sang Canonical Document IR do d òn s hu, sau ú Legal Structure Extractor trõch xut phõn cp phõp lut, cõc resolver xõc nh quan h tham chiu vi khõng hieu lc. Ch d liu qua quality gate vi c reviewer chp nhn mi c lu vĩa PostgreSQL vi index vĩa Qdrant.

Ingestion chy hoĩn toĩn nn qua Redis vi Dramatiq vi cõc actor ngñ, ri rc vi idempotent; API upload tr 202 Accepted kõm ingestion job ID, khũng parse PDF ng b trong request handler. PDF ngun vi artifact c lu trong MinIO, PostgreSQL gi object key vi metadata.

Pipeline hi ộp trc tuyn

Cóu hi ngi đứng → Query Understanding → Temporal Resolution → Query Expansion → Parallel Multi-Recall (exact | dense | sparse) → RRF Fusion → Reranking → Legal Context Expansion → Evidence Completeness Gate → Context Builder → Structured Generator → Verification (L1-L6) → Verified Answer hoc Abstention

Query Understanding trờch xut intent, ngi ộp dng, loi phng tin, nh danh vn bn vị evidence plan. Query expansion luũn gi cóu hi gc ca ngi đứng; HyDE ch bt cú iu kin vị không cú vùng rewrite không gii hn. Truy xut gm ba kỏnh song song: exact legal lookup, dense semantic vị sparse BM25, c hp nht bng RRF, rerank ri m rng ng cnh phỏp lý theo quan h quanh còc seed provision mnh. Evidence Completeness Gate kim tra mi loi bng chng cn thit ỏ cú; nu thiu, h thng chy targeted retrieval hoc m rng theo quan h trc khi sinh cóu tr li. Kt qu c kim chng sòu tng vị ch tr ra khi hp l; nu không, h thng t chi vị lý do chun.

Trờch xut vị mũ hnh d liu phỏp lý

Phng òn thit k u tiỏn da trỏn UDEF lịm tng x lý tị li. Phiỏn bn v2 loi b hoịn toịn ph thuc nịy vị thay bng ba thnh phn do d òn s hu: Parser Router c trc tip tị li, Canonical Document IR lịm biu din trung gian parser-neutral vị Legal Structure Extractor chu toịn b vic nhn din cu trức. Thay i nịy gim tng chuyn i trung gian vị kim sòt trc tip vic nhn din phón cp phỏp lut Vit Nam.

Canonical Document IR gm ParsedDocument cha ParsedPage, mi trang cha DocumentElement. Mi element mang element_id, element_type, text, page_number, bbox, reading_order, parent_element_id, table_html, source_parser, parser_version, parser_confidence vị raw_reference. Tng IR cũ lp phón tỏch phỏp lý khi nh dng u ra ca Docling/MinerU; thay hoc nóng cp parser ch cn mt adapter mi.

Legal Structure Extractor lị parser phỏp lý riỏng ca d òn, nhn din Chng, Mc, iu, Khon, im, Ph lc, bng phỏp lý, iu khon chuyn tip vị ònh s vn bn phỏp lut Vit Nam kỏm bin th do OCR. Bt buc h tr nhỏn im ting Vit a) b) c) d)) e) theo bng ch còi 29 kỳ t, không đứng gi nh [a-z]; khi OCR không phón bit c d) vị), extractor gn c ambiguity vị nh tuyn review. im phỏp lý ngn nhng hp l vn c gi (short-Point retention). Provision ID gi nguỷn kỳ t ting Vit trỏnh va chm, vò d im) ng diem- khỏc vị im d) ng diem-d.

Mi n v phỏp lý c biu din bng LegalProvision vị provision_id n nh vị tòi to c theo quy tc xỏc nh trc, vò d nd-168-2024__dieu-7__khoan-4__diem-b. Mũ hnh phón bit source_text (ni dung phỏp lý gc, bt bin, không bao gi b bin i) vị retrieval_text (cú th k tha ng cnh cha nh cóu m u ca Khon hoc tiỏu iu phc v retrieval). Trờch dn vn tr ti provision thc t. Ngoịi ra cùn cú khong hiu lc, trang ngun, bounding box, source_element_ids, content_hash vị review_status. Khi provision b sa i, provision_id gi nguỷn trỏch dn n nh, ni dung mi c lu di version mi vị khong hiu lc mi.

Quan h gia còc quy nh c lu trong bng PostgreSQL vị x lý bng application logic, không đứng Neo4j. ProvisionReference gm bn loi PARENT_OF, REFERS_TO,

SIBLING_OF và PENALTY_COMPANION, trong đó PENALTY_COMPANION quản lý các quy định về quy định i kèm theo các quy định pháp luật xe học tập quản lý các quy định pháp luật xe. DocumentRelation gồm AMENDS, REPEALS, SUPERSEDES, CORRECTS, GUIDES và RELATED_TO. LegalEffectEvent ghi lại các sự kiện pháp lý như các hiệu lực, sai sót, thay thế học bổng bổ sung và temporal resolver và cấu hình so sánh lịch sử. Quản lý không gửi quyết định tuyển review, không suy đoán.

PostgreSQL là nguồn dữ liệu nghiệp vụ chính, lưu trữ phiên bản và bản, không hiệu lực, quản lý, review, audit, query trace và evaluation run. Qdrant là index để xuất, lưu trữ các thông tin về PostgreSQL và chỉ nhận dữ liệu có `review_status = ACCEPTED`.

Truy xuất nhận biết cụ thể và thời gian

Hệ thống xử lý nhận biết pháp lý trực tiếp, chunking chỉ xảy ra sau đó: nhận biết chunk phi trùng nhận biết trích dẫn. Mỗi provision có embed để dùng để tìm kiếm; khi một provision được đặt, hệ thống trích theo cấu trúc và gửi cấu trúc provision_id. tìm kiếm có bổ sung ngữ cảnh của retrieval_text và mang nghĩa khi truy xuất các lần.

Retrieval là pipeline nhiều tầng:

1. exact legal lookup xử lý các danh sách xử lý 168/2024/N-CP, điều 7, Khoản 4, item a;
2. dense retrieval bằng embedding từ retrieval_text;
3. sparse retrieval bằng BM25 trong Qdrant cho các hiệu lực cụ thể pháp lý;
4. kết hợp giữa dense và sparse bằng Reciprocal Rank Fusion;
5. reranking bằng Jina Reranker v3 như stage chung, chưa tính đến các chỉ số khi benchmark;
6. mở rộng ngữ cảnh pháp lý quanh seed mạnh theo parent, sibling, cross-reference và penalty companion, mỗi provision mở rộng ghi lại do ngữ cảnh.

Mỗi query có một ngày cập nhật. Một provision chỉ có xem lại một lần:

$$effective_from \leq query_date$$

với effective_to là ngày học query_date < effective_to, ngày thì review_status = ACCEPTED. Temporal filter là điều kiện bắt buộc trong mỗi retrieval. Hệ thống không dừng và bản hình ảnh mới nhất cho cấu hình lịch sử. Vì cấu hình so sánh, hệ thống tạo hai context các lần và không tính citation giữa hai lần.

Dense embedding của các chỉ số vĩnh viễn. Suite B benchmark ba ngày với Gemini Embedding 2, Jina Embeddings v5 text-nano và Jina Embeddings v5 text-small từ cấu hình pháp luật tính từ khi chuyển embedding production.

Sinh cấu trúc và kiểm chứng trích dẫn

Mô hình ngôn ngữ chờn lị Gemini 3.5 Flash vì structured output theo schema cp claim: answer_summary, claims (mỗi claim gồm claim, claim_type, provision_ids, numbers), missing_information và should_abstain. Mô hình không có prompt với citation đúng và bản thân do; mỗi claim chỉ có provision_id từ context để truy xuất vị m rng. Citation hình thức đúng và metadata để lưu, không phải chui LLM gửi đi do.

Verifier thực hiện sâu theo thứ tự:

1. L1 Schema: output tuân thủ Pydantic schema cp claim;
2. L2 Citation ID: provision tồn tại, có truy xuất học m rng hợp lệ, có `review_status = ACCEPTED`;
3. L3 Temporal: provision trích dẫn có hiệu lực tại ngày cần hi;
4. L4 Numeric grounding: mức phần trăm, số lượng, thời gian, số lượng khi giờ từ bằng chứng để chuẩn hóa;
5. L5 Claim support: quy tắc xác minh trực, LLM judge có lập chứng cứ cho từng hợp ngữ nghĩa và hình thức fail-closed;
6. L6 Evidence completeness: mỗi lỗi bằng chứng trong evidence plan có các claim cui bao phủ.

Nếu draft không hợp lệ, workflow không nên thun regenerate mà sẽ liệt kê theo lỗi: thiếu bằng chứng chi targeted retrieval rồi dùng lại context và regenerate; claim không có hình thức sinh lại từ bằng chứng hình thức; schema sai sinh lại structured output; xung đột thời gian truy xuất phiên bản ứng. Sẽ in repair có giới hạn cụ thể hơn; hệ thống trả về thời gian chi vì reason code chuẩn thay vì hình thức cấu trúc lại của kiểm chứng. Bấm API lị Returned Invalid Citation Rate bằng 0.

Citation hình thức gồm tồn và bản thân, số hiệu, iu, Khon, im, không hiệu lực, trạng thái vị on trích. Mỗi response đều kèm thông báo giới hạn trích nhằm phòng lỵ.

Vai trò người đứng

Người đứng cui

Người đứng nhập cấu trúc bằng tính Vit, có thể chọn ngày cập nhật vị lỗi phỏng tin. Hệ thống trả về kết quả trong hai kết quả:

- cấu trúc liệt kê các xác minh kèm citation vị on nguồn;
- thông báo chi, nỗ lực do thiếu dữ liệu học thiếu thông tin.

Người đứng có thể ở ngoài giờ cấu trúc liệt kê Useful học Not Useful kèm danh mục báo cáo (sai trích dẫn, thiếu thông tin, sai ngày hiệu lực, sai mức phần trăm, cấu trúc liệt kê không y , khác); feedback

c lu trong PostgreSQL vị gi v Langfuse. Ngì dúng cng cú th tòm trc tip iu, Khon hoc t khóa mị khũng cn gi mĩ hnh sinh cẩu tr li.

Corpus Reviewer

Reviewer kim tra PDF, metadata, hierarchy, provenance, quan h tham chiu vị hieu lc trong pipeline ingestion. Tị liu hoc provision c gi review khi metadata cha chc chn, cu trũc cha y , OCR coverage thp, quan h sa i hoc hieu lc khũng xỏc nh, hoc nhõn im ting Vit khũng t quality gate. Ch tị liu hoc provision cú trng thòi accepted mị c index. Human-in-the-Loop nm ti khৌ review ingestion, khũng nm trong mị cẩu hi ca ngì dúng.

Nhị phòt trin

Nhị phòt trin qun lý ingestion, database migration, Qdrant index vị collection versioning, model configuration, prompt version, evaluation, backup, restore vị release. Mị experiment phi lu corpus hash, gold-set hash, model ID, prompt version, cu hnh, git commit vị raw result.

Cũng ngh chõnh

Thịnh phn	Cũng ngh
Backend	Python 3.11, FastAPI, Pydantic v2
Workflow	LangGraph 1.x controlled workflow
Parser chõnh	Docling 2.x
Parser ph / fallback	MinerU 3.4.x (Parser Router)
D liu nghip v	PostgreSQL 18, SQLAlchemy 2, Alembic
Retrieval	Qdrant v1.19 dense + sparse + RRF + payload filter
Embedding	ng viõn: Gemini Embedding 2, Jina Embeddings v5 text-nano / text-small
Reranker	Jina Reranker v3 (stage chun)
Generator	Gemini 3.5 Flash
Evaluation judge	GPT-5.4 mini snapshot
õnh giõ	Deterministic metrics + Ragas v0.4.x
Background jobs	Redis + Dramatiq 2.x
Object storage	MinIO (S3-compatible)
Observability	Langfuse Cloud
Frontend	Next.js, TypeScript, shadcn/ui
Trin khai	Docker Compose, GitHub Actions

õnh giõ h thng

B gold set mc tiõu gm 200 cõu õ review, chia 40 development, 40 validation v 120 final test. Final test c úng bng v ỹ khũng đứng tuning. Cõc danh mc cõu hi gm hin hỡnh, lch s, so sõnh, tra cu chõnh xõc, mc pht, im giy phõp lờ xe, iu kin õp dng, ngoi l, th tc, tham chiu chõõ, a provision, a vn bn, cõu khu ng, thiũ thũng tin, ngoi corpus v ỹ cõu c tõnh yõu cu citation sai.

Cõc b thờ nghim:

- Suite A (parser): P1 Docling, P2 MinerU, P3 Parser Router;
- Suite B (embedding): E1 Gemini Embedding 2, E2 Jina Embeddings v5 text-nano, E3 Jina Embeddings v5 text-small;
- Suite C (retrieval): R1 n R10 b sung dn sparse/RRF, query normalization, multi-query rewrite, conditional HyDE, reranker, parent/sibling expansion, cross-reference expansion, temporal filtering;

- Suite D (generation và verification): G1 prompt-only, G2 structured output, G3 citation ID verifier, G4 temporal verifier, G5 numeric grounding, G6 claim support, G7 evidence completeness.

Các nhóm metric chính gồm retrieval (Recall@5/10/20, MRR@10, nDCG@10), evidence, temporal, citation (Precision, Recall, F1, Invalid Citation Rate), grounding (Numeric Grounding Accuracy, Unsupported Claim Rate, Claim Support Precision), corpus và abstention (Precision, Recall, F1). Deterministic metrics là headline; LLM judge chỉ là nguồn tham khảo.

Tại liệu không có như trước bởi vì không có nguồn dữ liệu. Không có các video bảo vệ sau khi chạy final evaluation trên corpus, gold set và các hình ảnh ứng dụng.

Trình khai và bảo trì

Hệ thống chạy local bằng Docker Compose với các service chính: frontend (Next.js), backend (FastAPI), worker (Dramatiq), PostgreSQL, Qdrant, Redis và MinIO. PostgreSQL và Qdrant có volume riêng. Qdrant là index dữ liệu, có thể rebuild từ PostgreSQL khi index hỏng bằng cách tạo collection mới rồi switch alias, không rebuild in place vì không trên hai embedding space. Langfuse Cloud là dịch vụ ngoài; nếu không có, query vẫn hoạt động với observability không cần trả về kết quả. RAGFlow chạy trong môi trường benchmark riêng, không cần trong compose production.

Release bundle gồm PostgreSQL dump, Qdrant snapshot, MinIO mirror, gold set, evaluation results, release manifest, git tag và checksum. Restore cần kiểm tra bằng script so sánh số point, hash corpus và migration revision.

Khi có vấn đề nào, hệ thống thực hiện quy trình:

Phát hiện → Tìm → Hash → Trích xuất → Validate → Review → Phiên bản → Cập nhật hiệu lực →
Index → Regression → Kiểm tra

Không append dữ liệu mới vào retrieval mà bỏ qua quan hệ thời gian. Vấn đề lịch sử vẫn có giá trị là có thể hiểu được, nhưng bị lỗi khi có hình ảnh bằng temporal filter.

Kết quả mong đợi

Sơ đồ khóa luận gồm:

- mã nguồn backend và frontend;
- Parser Router và bảo vệ parser benchmark;
- Canonical Document IR và Legal Structure Extractor;
- quan hệ tham chiếu ProvisionReference, DocumentRelation và LegalEffectEvent;
- PostgreSQL schema và Qdrant index;

- retrieval a tng vị Evidence Completeness Gate;
- verifier sòu tng;
- giao din chat, tòm kim vị xem ngun;
- gold set 200 còu vị bào cò còc suite A-D;
- Docker Compose, backup, restore vị release candidate;
- bào cò khóa lun vị slide bo v.

Tin

H thng c trin khai t ngiy 20/07/2026 n ngiy 12/09/2026. Feature freeze d kin ngiy 06/09/2026, code freeze ngiy 10/09/2026, rehearsal ngiy 13/09/2026 vị bo v ngiy 14/09/2026.

Tji liu k thut tham kho

- Google Gemini API documentation: <https://ai.google.dev/gemini-api/docs>
- Qdrant hybrid queries: <https://qdrant.tech/documentation/search/hybrid-queries/>
- Docling documentation: <https://docling-project.github.io/docling/>
- MinerU documentation: <https://opendatalab.github.io/MinerU/>
- LangGraph documentation: <https://langchain-ai.github.io/langgraph/>
- Langfuse documentation: <https://langfuse.com/docs>
- Jina AI API: <https://jina.ai/>
- Dramatiq documentation: <https://dramatiq.io/>
- MinIO documentation: <https://docs.min.io/>
- RAGFlow documentation: <https://ragflow.io/docs/>
- PostgreSQL documentation: <https://www.postgresql.org/docs/18/>