

BÀI MÔ TẢ HỆ THỐNG CHATBOT AI TÍCH HỢP TRÍCH XUẤT TÀI LIỆU

Hệ thống là giải pháp kết hợp giữa trích xuất tài liệu tự động và chatbot trí tuệ nhân tạo, cho phép người dùng đặt câu hỏi về nội dung tài liệu và nhận câu trả lời chính xác kèm trích dẫn nguồn. Hệ thống gồm ba tầng: tầng trích xuất xử lý tài liệu đầu vào thành dữ liệu có cấu trúc, tầng lưu trữ và truy xuất quản lý dữ liệu đã trích xuất, và tầng chatbot trả lời câu hỏi bằng mô hình ngôn ngữ lớn. Kiến trúc này cho phép hệ thống áp dụng cho nhiều lĩnh vực: từ tra cứu pháp luật giao thông, quản lý nhà trọ, đến xử lý chứng từ tài chính và hồ sơ nghiệp vụ.

Tầng trích xuất tài liệu

Tầng trích xuất tiếp nhận tài liệu đầu vào ở nhiều định dạng: PDF, ảnh scan, bảng tính. Hệ thống sử dụng Docling để phân tích cấu trúc tài liệu, nhận diện bảng biểu, hình ảnh và luồng văn bản. Kết quả phân tích được ánh xạ vào mô hình tài liệu chuẩn (Canonical Document Model, CDM) với cấu trúc phân cấp: tài liệu chứa các phần, mỗi phần chứa các đoạn văn bản, bảng biểu và hình ảnh kèm thông tin vị trí trang và dòng.

Sau khi có CDM, tầng xử lý quy tắc (Rule Engine) thực hiện trích xuất các trường thông tin quan trọng dựa trên tập cấu hình theo lĩnh vực. Quy trình gồm bốn bước: xác định vị trí thông tin trong tài liệu (locate), trích xuất giá trị (extract), chuẩn hóa dữ liệu (normalize) và kiểm tra tính hợp lệ (validate). Mỗi giá trị trích xuất đều kèm dấu vết nguồn (provenance) ghi lại trang và dòng trong tài liệu gốc, phục vụ kiểm toán và đối chiếu sau này.

Hệ thống hỗ trợ kiến trúc plugin cho phép mở rộng sang lĩnh vực mới mà không cần sửa đổi phần lõi. Nhà phát triển chỉ cần viết plugin và tập cấu hình quy tắc cho lĩnh vực đó; phần xử lý tài liệu, nhận diện chữ viết, phân tích bảng biểu và kiểm tra dữ liệu do hệ thống đảm nhiệm.

Tầng lưu trữ và truy xuất

Dữ liệu sau trích xuất được tổ chức thành các đoạn văn bản (chunk) theo cấu trúc logic của tài liệu gốc. Mỗi chunk mang metadata giàu: định danh tài liệu, vị trí trong cấu trúc phân cấp, và dấu vết nguồn. Các chunk được nhúng thành vector 384 chiều bằng mô hình `intfloat/multilingual-e5-small` và lưu vào cơ sở dữ liệu vector ChromaDB.

Hệ thống sử dụng truy xuất lai (hybrid retrieval) kết hợp hai phương pháp: tìm kiếm

ngữ nghĩa bằng vector embedding (dense retrieval) và tìm kiếm từ khóa BM25 Okapi (sparse retrieval). Kết quả từ hai phương pháp được hợp nhất bằng thuật toán Reciprocal Rank Fusion (RRF). Metadata từ tầng trích xuất cho phép lọc chính xác theo lĩnh vực, loại tài liệu, hoặc khoảng thời gian.

Tầng chatbot trả lời câu hỏi

Khi người dùng gửi câu hỏi, tầng chatbot kích hoạt chuỗi xử lý trạng thái sử dụng LangGraph. Quy trình gồm các bước:

- Viết lại câu hỏi để tối ưu truy xuất.
- Truy xuất lại trên ChromaDB và BM25 để lấy các chunk liên quan.
- Chấm điểm chất lượng kết quả truy xuất bằng mô hình ngôn ngữ.
- Nếu điểm thấp, viết lại câu hỏi và truy xuất lại hoặc chuyển sang tìm kiếm web dự phòng.
- Sinh câu trả lời dựa trên ngữ cảnh các chunk đã truy xuất.
- Kiểm tra từng trích dẫn trong câu trả lời có khớp với nguồn thực tế hay không.
- Stream câu trả lời đã kiểm duyệt về giao diện qua SSE.

Mô hình ngôn ngữ chính là Google Gemini 2.5 Flash với free tier 250 request mỗi ngày. Khi vượt định mức hoặc gặp lỗi, hệ thống tự động chuyển sang OpenAI GPT-4o-mini. Mô hình phụ này cũng đóng vai trò giám khảo độc lập trong quy trình đánh giá chất lượng, tránh thiên vị do cùng một mô hình vừa sinh câu trả lời vừa chấm điểm.

Câu trả lời trả về dưới dạng Markdown kèm danh sách trích dẫn có cấu trúc: tên văn bản, số Điều, Khoản, Điểm, trạng thái hiệu lực và dấu vết nguồn (trang, dòng). Mọi câu trả lời đều kèm điều khoản miễn trừ trách nhiệm pháp lý.

Vai trò người dùng

Người dùng cuối

Người dùng cuối tương tác với hệ thống qua giao diện trò chuyện. Họ nhập câu hỏi bằng ngôn ngữ tự nhiên và nhận câu trả lời ngắn gọn kèm trích dẫn. Hệ thống phục vụ nhiều đối tượng: người tham gia giao thông tra cứu mức phạt, sinh viên luật tìm điều khoản, chủ nhà trọ tra cứu hợp đồng thuê, nhân viên tín dụng kiểm tra lịch trả nợ.

Nhà quản trị và phát triển

Nhà quản trị chịu trách nhiệm cập nhật cơ sở dữ liệu tài liệu và theo dõi hiệu năng hệ thống. Họ nạp tài liệu mới qua API được xác thực bằng Bearer Token; quy trình tự động thực hiện trích xuất, nhúng vector và tái xây dựng chỉ mục BM25 mà không làm gián đoạn luồng tra cứu. Nhà phát triển mở rộng hệ thống sang lĩnh vực mới bằng cách viết plugin và tệp cấu hình quy tắc, không cần can thiệp vào phần lõi xử lý.

Kiến trúc hệ thống

Hệ thống vận hành trên kiến trúc đa tầng:

- FastAPI làm khung API cho cả tầng trích xuất và chatbot.
- LangGraph làm bộ điều phối trạng thái cho luồng xử lý chatbot.
- ChromaDB làm cơ sở dữ liệu vector cho truy xuất ngữ nghĩa.
- SQLite cho lưu trữ trạng thái hội thoại và lịch sử.
- Hệ thống tệp cho tài liệu PDF gốc và chỉ mục BM25.
- Công cụ dòng lệnh cho quy trình nạp dữ liệu hàng loạt.

Hệ thống chạy trên một worker duy nhất do ChromaDB dùng SQLite nội bộ, không hỗ trợ nhiều tiến trình ghi đồng thời. Toàn bộ mô hình ngôn ngữ và nhúng vector chạy qua API cloud; card đồ họa MX330 2GB VRAM trên máy phát triển không đủ để chạy inference cục bộ.

Bảo mật

Hệ thống tuân thủ Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân: không lưu trữ thông tin nhận dạng ngoài mã định danh phiên, chính sách lưu trữ tối đa 30 ngày, xác thực API bằng Bearer Token, giới hạn tốc độ 6 request mỗi phút mỗi địa chỉ IP.